

选题方向四 · 金融风控与理赔自动化

信衡 CreditSentry

贷后风险预警到授信处置的
多 Agent 可举证自主闭环系统

AgentTeams 6 职能 Worker 14 Skill 4 MCP Server 证据账本

队伍名称: <队伍名称>
团队成员: <成员A> / <成员B> / <成员C>



让每一笔风险处置都能对监管举证

我们不做「AI 预警」。银行不缺预警系统，缺的是**敢自动执行、又能担责举证**的处置闭环。

我们做什么

面向银行小微与对公信贷**贷后管理**：从风险信号进入，到取证、定性、质疑、分级处置、合规审计与经验回流的端到端闭环。

输入：预警信号 / 征信 / 司法工商 / 流水
输出：处置意见书 + 审计报告 + 证据链

为什么难

难点不在「发现风险」，在**敢不敢动手**。压降额度、提前收贷都会直接影响企业经营，一旦误判即引发投诉与监管问责；而处置全程必须可追溯、可解释、可复核。

所以：既要自动化，又不能失控。

凭什么不同

- ① **内控即拓扑** Agent 数量由权限等价类推导，不是拍脑袋。
- ② **证据账本 + 对抗裁决** 无证据不决策，质疑官不可跳过。
- ③ **执行闸门 L0—L3** 不可逆动作永不自动执行。

对评委最关心问题的正面回答 —— 「为什么要多 Agent，不能一个大 Agent 干完？」

因为单 Agent 在**结构上**无法满足金融内控的「不相容职务分离」要求。取证者不能同时定性，执行者不能同时审计。多 Agent 在本场景是**合规刚需**，不是技术炫技。

≥60%

预警降噪率

≥85%

风险定性准确率

≤2%

误杀率（好客户被误处置）

100% / 0

证据完备率 / 无证据结论率

100%

高风险动作审批覆盖率

上述为 Demo 评测目标值，基于合成与公开数据的回放评估集测得，非行业统计数据。

四个真实痛点，四条对应设计

目标用户：客户经理、风险经理、贷后管理岗、内审与合规岗。场景来源于商业银行 / 城商行 / 农商行小微与对公贷后管理的日常作业。

核心痛点	本方案对应设计	落点
1 风险预警数量庞大，人工筛查成本高，客户经理难以及时识别真正高风险事件	SignalHub 多源信号聚合降噪 + ExposureMapping 敞口与担保圈测绘，把海量零散信号收敛为少量带影响面的风险事件；被丢弃信号全部可回溯，杜绝静默漏丢	Skill 1·2
2 风险核查涉及工商、司法、征信、流水等多个系统，证据分散、核查耗时	DueDiligence 作为唯一取证触点，经 4 个 MCP Server 统一接入外部系统；所有原文经 EvidenceLedger 集中登记、哈希存证并评定证据等级	4 × MCP
3 贷后报告和风险处置依赖人工撰写，标准不统一，经验难以沉淀复用	能力全部 Skill 化以统一口径与 Schema；ReportCompose 自动成文并注入证据引用角标；PostmortemDistill 把已核实案件沉淀为 RiskPattern 与向量案例回流	14 × Skill
4 风险处置全过程需满足监管要求的可追溯、可解释、可复核，现有系统证据链管理不足	证据账本 append-only 不可篡改 + 全链路 Trace（含路由决策 Span）+ 执行闸门审批留痕 + ComplianceCheck 逐条举证的审计报告	证据链 + Trace

行业可复制性

本方案的可迁移资产是**拓扑与契约**，不是业务规则。更换 MCP 数据源与领域 Skill 后，同一套 Agent 拓扑、证据账本、执行闸门可直接平移到：

- 保险理赔核赔
- 供应链金融
- 反洗钱可疑交易调查
- 券商适当性管理
- 医保基金监管

数据来源与合规边界

全部使用**合成数据 + 公开数据**（裁判文书网公开样例、国家企业信用信息公示系统公开字段、公开财报），**不含任何真实银行客户数据**。企业主体、账号、金额均为构造值。

Demo 场景：一次小微企业风险预警到授信处置

同一主体、两条链路：一条证明**敢**处置，一条证明**不误杀**。两条链路均产出可截图的 Trace 时间线与报告文件。

案件档案（合成数据）

浙 XX 精密机械有限公司

CASE-2026-0814-001

授信总额

800 万

当前敞口

620 万

担保圈主体

3 户

当前分类

正常

触发信号（3 类）

· 新增涉诉 3 笔

· 近 30 日流水集中转出 480 万

· 法定代表人变更



对照人工基线：同类案件从信号进入到处置意见书完成，通常需 0.5 — 2 个工作日。

链路 A

风险成立 → 分级处置

三类信号相互印证：涉诉标的合计 186 万（占敞口 30%）且均未结案；流水集中转出对手方为关联方；法定变更与涉诉时间窗重合。

质疑官提出「行业淡季资金调度」的替代解释，但**反证不成立**（对手方为关联方而非供应商）。

裁决：关注类 · L2 · 额度压降 30% + 追加担保

链路 B

误报 → 被质疑官驳回

同一主体的另一批信号：涉诉为买卖合同纠纷，标的 5 万（占敞口 0.8%）、已结案且我方为原告；流水在正常季节波动区间。

质疑官举出三项反证，定性结论被推翻，Case **不进入 DISPOSITION**。

裁决：维持原状 + 加强监测（L0）

链路 B 才是真正的技术难点 —— 让 Agent 敢说「这不是风险」，比让它报警难得多。

总体架构：AgentTeams + Skill + MCP + 证据治理

四层职责严格分离：Agent 只做判断与协作，Skill 承担能力抽象，MCP 承担工具连接，证据层承担举证与审计。Agent 不裸调工具。

接入层 Matrix Room	风险预警推送 · 人工指令与干预 · 审批回调 · 处置意见书与审计报告下发 —— 一案一房间，人始终在房间内
AgentTeams 编排层 Manager / Team Leader	SOP 五阶段状态机路由 · 任务 fan-out · 冲突裁决 · 风险分级 · 审批发起 · 跨 Team 移交
多 Agent 协同层 6 职能 Worker	SignalHub DueDiligence RiskAnalyst DevisAdvocate Executor Auditor
Skill 能力层 L3 自研 / L2 封装 / L1 官方	诊断 · 取证 · 知识 · 治理 · 执行 五类共 14 个 Skill，统一 Schema、失败处理、安全边界与回归评估集
MCP / 适配器层 Higress 统一出口	credit-core-mcp bureau-mcp judicial-mcp txn-mcp
证据与治理层 append-only	证据账本 · Case State · 全链路 Trace / Log / Metrics · 审批与回滚记录 · RiskPattern 知识库

贯穿能力

- 凭证隔离 Worker 只持 consumer token，不碰真实密钥
- PII 出站脱敏 取证触点唯一，脱敏范围可收敛
- 版本治理 Skill / Prompt / 路由表经 Nacos 灰度与回滚
- 幂等与回滚 所有写动作带幂等键与回滚点
- 全链路可回放 含路由决策 Span，可举证

推荐组件：Nacos（治理）· Higress（网关）· PolarDB PG + pgvector（数据层）· RocketMQ（事件）· LoongSuite + AgentScope Studio（可观测）

Agent 数量不是拍出来的，是数出来的

法则：Agent 边界 = 工具权限边界，不是业务步骤边界。按此法则，本方案的 Worker 数量可推导、可证伪。

工具 / 权限	SIGNAL HUB	DUE DILIGENCE	RISK ANALYST	DEVILS ADVOCATE	EXECUTOR	AUDITOR
内部预警池（读）	●					
敞口 / 担保圈图谱（读）	●					
征信 bureau-mcp（读 · PII）		●				
司法工商 judicial-mcp（读）		●				
交易流水 txn-mcp（读 · PII）		●				
信贷核心（读）	●	●			●	●
信贷核心（写 · 额度变更）					●	
证据账本（写）		●				
政策 / 案例 RAG（读）			●	●		●
全链路 Trace（读）						●
知识库 RiskPattern（写）						●
LLM 自由推理	●	●	●	●	仅规则	●

此矩阵即 Worker CR 配置，可 diff、可在 CI 中断言 —— 架构约束从「文档承诺」变成「可执行校验」。

拆分判据

- 必须拆，当且仅当：
- (i) 权限集不可安全合并（合并即越权）；
 - (ii) 目标函数相互对立（同上下文会自洽坍塌）。
- 必须合并：权限集相同 + 目标一致 + 失败策略相同。

推导结果

6 = 5 个权限等价类 + 1 个目标函数对立拆分

RiskAnalyst 与 DevilsAdvocate 权限完全相同，但一个求证风险成立、一个求证不成立，必须隔离上下文。

反向检验

为什么不是 4？合并即越权：取证 + 定性 → 确认偏差且 PII 触点扩散；定性 + 质疑 → 对抗坍塌；执行 + 审计 → 违反不相容职务分离。

为什么不是 10？把取证官再拆成征信 / 司法 / 流水三个，三者权限集、目标函数、失败策略完全相同，按合并判据必须合并；拆分只增跳数与 Token，不增控制力。

7 个身份，每个都写明「不可以做什么」

Identity 清单的关键不是能力列表，而是**刻意的能力剥夺**——那才是内控落地的证据。完整字段见附录 A。

NAME	ROLE	能做	不能做（能力剥夺）	决策边界
risk-commander	Team Leader 路由与裁决	阶段状态机路由、任务 fan-out、冲突裁决、风险分级、发起审批、升级人工	不得调用任何取证或处置工具；不得修改证据账本；不得跳过 DevilsAdvocate	L0/L1 自主 · L2 发起审批 · L3 只出方案
signal-hub	信号聚合 与影响面测绘	跨源归并去重、噪声压降、敞口与担保圈 / 集团户 / 上下游测绘	不得判断风险是否成立；不得访问征信 / 司法 / 流水等外部 PII 源	全自主（纯只读）
due-diligence	尽调取证 唯一 PII 触点	调取征信、裁判文书、工商、流水、押品原文，结构化抽取并登记证据与证据等级	不得给出风险定性结论；不得提出处置方案；不得写信贷核心	全自主（只读 + 写账本） PII 强制经网关脱敏
risk-analyst	风险定性 零工具权限	基于已登记证据做根因归因，给出五级分类建议、置信度与证据引用	不得自行取证（防「边查边下结论」的确认偏差）；不得执行处置	只有提议权，无执行权 证据不足须输出缺口清单
devils-advocate	对抗质疑 目标函数对立	提出反证与替代解释、指出证据不足与逻辑跳跃、质疑证据时效性与代表性	不得提出处置方案（避免既当质疑者又当决策者）；不得自行取证	对自动执行有一票阻断权 判定证据不足即强制回退补证
disposition-executor	处置执行 唯一写触点	执行白名单动作：打标关注、发起补充资料、额度压降、追加担保、生成收货方案	不得自主决定是否执行；不得执行白名单外动作；不得审计自身结果	零自主决策 仅规则驱动 L3 永不执行

每个 Agent 的身份以 SOUL.md 声明，权限以 Worker CR 声明——身份与权限分离，各自可独立审计与版本管理。

逐条映射到 AgentTeams 真实原语

AgentTeams（开源名 alibaba/hiclaw）不是一个被提及的名字，而是本方案的协同基点。以下为角色编排、任务拆解、上下文传递、协同执行与状态追踪的落点。

AGENTTEAMS 原语	本方案用法
Manager Agent	人机会话入口 · case room 生命周期 · 跨 Team 移交 （见右侧取舍说明）
Team Leader	risk-commander: SOP 五阶段状态机路由、冲突裁决、风险分级、发起审批
Worker CR (K8s YAML · spec.env · 声明式 MCP)	6 个 Worker 的声明式定义，MCP 与权限挂在 CR 上 —— 权限矩阵即 CR 配置 ，可 diff、可审计
SOUL.md (Worker 包内身份定义)	职责 · 能力边界 · 决策边界 · 禁止事项 ；与权限配置分离，各自独立版本管理
Matrix Room (Element 客户端 · 人在房间内)	一案一房间 ：Agent 对话全程可见、可介入。人工审批即在房间内 @ 风险经理完成 —— 协同过程本身就是审计留痕
MinIO S3 文件共享	Agent 间传递证据附件：征信报告快照、裁判文书 PDF、流水明细 —— 大对象不进消息体
Higress AI Gateway (凭证透传)	Worker 只持 consumer token、不碰真实密钥；统一 LLM / MCP 出口 + PII 出站脱敏
Nacos 远程 Skill Registry	Skill / Prompt / AgentSpec / 路由表 的版本治理、标签灰度、快速回滚
Worker 运行时 openclaw / copaw / hermes	纯推理型 Worker (Analyst / Advocate) 选轻量运行时；取证与执行型选具备工具沙箱的运行时
agt CLI + Helm Chart	本地 Docker 一键起全栈用于 Demo；Helm 部署用于复赛集群环境，两者共用同一套 CR

Manager 是否多余？我们的诚实取舍

在单一贷后场景下，Manager 确实接近透明 —— 我们不为它编造职责。

它不可省的只有三件事：

- 人机会话入口与实时干预
- 多案并发时 case room 的创建、归档与超时回收
- 跨 Team 移交** —— 涉嫌欺诈移交反欺诈 Team、需诉讼保全移交法务 Team

若砍掉它，Team Leader 需同时承担人机接口 + 领域调度 + 跨团队移交，SOUL 显著变胖；且**跨 Team 就必须持有他团队权限**，破坏最小权限原则。


取舍：初赛保持框架默认的极薄 Manager，复赛扩展至「贷后 + 反欺诈 + 法务」三 Team 时才变厚。

状态追踪如何映射

Case State 独立于 Matrix 消息流存储（Postgres），消息只承载事件与结论引用。房间提供人可读的协作轨迹，Case State 提供**机器可查的一致性状态**，两者以 case_id 关联。

RiskCommander 如何路由：SOP 状态机，不是「智能路由」

核心原则：LLM 只做阶段内判定，不决定流程走向。金融场景要求可复现、可审计 —— 纯 LLM 自由编排不可审计，因此流程骨架必须是确定性的。



① 路由键 (Routing Key)

```
(phase,
signal_type,
evidence_sufficiency,
risk_tier,
exposure_amount)
```

五元组决定下一跳。所有维度均为结构化字段，不依赖自然语言判断。

② 路由表 (可灰度 · 可回滚)

声明在 Team CR / Nacos，与代码解耦。硬约束写死在表里，不交给 LLM 判断：

- ADJUDICATION 强制并行 fan-out 给定性官与质疑官，不可跳过
- 收敛规则：证据等级优先于置信度
- 全流程仅一条回退边，杜绝无限循环

③ 异常路由与并发

- Worker 超时 / 失败 → 按 Skill 声明的 failure policy 执行 **retry / degrade / escalate**
- 连续失败 → 升级人类 (Manager 拉人进房间)
- 并发一致性：乐观锁 + RocketMQ 顺序消息，同一 case_id 路由至同一队列

路由决策本身就是一条 Trace Span —— 记录 routing_key、命中规则 ID、规则版本，「为什么当时走了这条分支」可举证、可回放

无证据不决策，质疑官不可跳过

数据不完整时不编造结论，而是输出**证据缺口与取证任务**。这是「可举证」区别于「看起来很聪明」的分界线。

证据账本 EVIDENCE LEDGER

```
Evidence {
  evidence_id   : "EV-0814-0007"
  source_system : "judicial-mcp"
  snapshot_uri  : "s3://ledger/...pdf"
  content_hash  : "sha256:4f2a..."
  collected_at  : "2026-08-14T10:17:22Z"
  level         : "强" | "弱" | "缺失"
  level_reason  : "原文可溯源且时间窗吻合"
}
```

- 强

原文可溯源、时间窗与异常吻合、来源权威 —— 可直接支撑处置决策
- 弱

采样不足、间接推断、时效存疑 —— 可作旁证，不可单独定性
- 缺失

应有而未取到 —— 触发取证任务，不允许以推测填补


三条硬约束

• 任何外部原文取回时**强制登记**，不经账本的数据不得进入决策

• 结论 Schema 要求挂载 evidence_ids，**无证据的断言被直接拒绝**

• 账本 **append-only** 不可篡改，报告正文自动注入证据引用角标

对抗式双轨裁决 ADVERSARIAL ADJUDICATION



为什么必须是两个独立 Agent

LLM 强烈倾向于让自己的前后输出保持一致，因此**无法在同一上下文里真诚地自我反驳**。让同一个 Agent 「先定性再自查」，质疑会沦为走过场。

质疑官对**自动执行**拥有一票阻断权：一旦判定证据不足，Case 强制回退 EVIDENCE 补证，不得进入 DISPOSITION。

领域判断力自研，通用云操作复用官方

我们不重复造基础能力的轮子。评审重点不在堆叠工具数量，而在必要性、接口契约、可替换性与迁移成本 —— 以下是我们的分工依据。

L3 领域判断层 · 全自研 10 个

承载信贷风控领域知识、监管条款绑定与证据语义，无法也不应外包。**核心资产与开源贡献物。**

诊断	SignalFusion · ExposureMapping · RiskRootCause
取证	CreditReportProbe · LitigationProbe · TxnFlowAnalyze
治理	RiskGate · ComplianceCheck
执行	SafeDisposition · PostmortemDistill

L2 领域封装层 · 自研外壳 4 个

领域语义自研，底层存取与检索复用官方能力 —— **两层之间的接缝。**

SKILL	自研部分	复用官方
EvidenceLedger	证据定级 · 哈希存证	对象存储 + DB
PolicyRag	条款切分与对齐	向量检索
CaseMemory	案例模板与时窗	向量 + DB
ReportCompose	模板与证据注入	对象存储归档

L1 云操作层 · 直接调官方，不自研

对象存储存取 · 向量库与数据库操作 · 日志服务检索 · 云监控指标 · 消息通知 · RAM 鉴权。

这正是赛题对云 Skills 的定位 —— 「不再需要额外构建一些基础能力的 Skill」，使我们能聚焦领域 Skill 构建。

鉴权经 Higress 统一签发 consumer token，Worker 侧无长期密钥。

可替换性：无厂商锁定

官方能力	开源等价替代	迁移成本
对象存储 OSS	MinIO	换 endpoint 与凭证，S3 协议兼容
日志服务 SLS	Loki	查询语法适配层约 1 个文件
向量检索	pgvector	共用 L2 VectorStore 接口
云监控 CMQ	Docker	CT + F + ... 直接切换

Skill 即合规资产：版本治理闭环

Skill 绑定**监管条款引用 + 生效日期 + 回归评估集**。监管口径变化时升 Skill 版本，**不改 Agent 代码**。

定义 Spec → 安全审核 → **Nacos** 标签灰度
→ 运行时按标签加载 → 调用审计回传版本
→ **异常一键回滚**

CreditSkill Spec：让 Skill 可分发、可评估、可回滚

在赛题附录 B 的 10 个字段基础上，增加两个金融特色字段：**绑定监管条款** 与 **回归评估集**。规范本身即开源贡献物。

统一三件套

```
skills/<name>/
├─ SKILL.md
│   12 个字段全填
├─ schema.json
│   运行时强校验
└─ eval/
    ├─ cases.jsonl
    └─ expected.jsonl
    全绿才可发布
```

目录与元数据格式对齐 skills.sh 与 Nacos Skill Registry，**保证可分发**。

完整 14 个 Skill 清单见附录 B。

RiskGate

安全核心 · 纯自研

用途	计算处置动作的执行层级 L0—L3
输入	risk_grade, evidence_level, exposure_amount, action_type, reversibility
输出	action_tier, 需审批, 审批角色[], idempotency_key, rollback_point, 判定理由
调用条件	进入 DISPOSITION 时 强制 调用，无旁路
依赖	纯规则引擎， 无外部依赖 —— 安全判定不依赖网络与 LLM
失败处理	任何入参缺失或规则未命中 → 默认降级为 L3 （只出方案不执行）。 fail-safe 而非 fail-open
安全边界	规则表经 Nacos 版本管控，变更需双人审核；判定结果写审计日志
监管条款	《商业银行内部控制指引》授权审批与不相容职务分离
回归评估	全组合边界用例，校验 不可逆动作永不落入 L0/L1
复用价值	四维闸门是 场景无关 的高风险动作管控内核，可直接复用于运维自愈、保险赔付、自动化交易

EvidenceLedger

自研 + 官方复用的接缝

用途	登记证据、哈希存证并评定证据等级
输入	source_system, raw_content, extracted_fields, collected_at, subject_id
输出	evidence_id, snapshot_uri, content_hash, level, level_reason
调用条件	任何外部原文取回时 强制 调用 —— 不经账本的数据不得进入决策
依赖	自研 ：证据定级、哈希存证语义、引用约束校验 复用官方 ：对象存储（快照）+ 数据库写入
失败处理	存储不可用 → 本地暂存队列 + 后台补偿；哈希冲突 → 拒绝写入并告警
安全边界	仅 DueDiligence 可写；账本 append-only 不可篡改；快照加密存储
监管条款	《商业银行内部控制指引》记录留存与可追溯要求
回归评估	定级规则全覆盖 + 幂等写入 + 哈希校验
复用价值	本项目最通用的开源组件 —— 任何需要「结论可举证」的 Agent 系统均可直接接入

4 个 MCP Server：Mock 与真实接入零 Schema 差异

关键设计原则 —— 初赛以 Mock 实现，但与真实系统共用同一套 Schema 与契约；复赛只换实现，不改调用链。这决定了迁移成本是「协议适配」而非「重新设计工具调用链」。

MCP SERVER	接入系统	核心工具 (TOOL)	权限范围	失败处理与降级
credit-core-mcp	信贷核心 / 额度管理	get_facility · get_exposure · get_collateral · adjust_limit · add_guarantee · rollback_adjustment	读 + 写 写仅 Executor	写操作幂等键去重；中断按 rollback_point 自动冲正；回滚失败即冻结 Case 并升级人工
bureau-mcp	征信系统	get_credit_report · diff_report · get_query_history	只读 · PII	限流 → 指数退避重试 3 次；无授权查询立即失败并记合规事件，绝不降级绕过
judicial-mcp	司法涉诉 / 工商登记	search_litigation · get_judgment_doc · get_business_registration · get_change_history	只读 (公开数据)	超时 → 返回部分结果并标注 partial；重名无法消歧 → 输出候选集标注 ambiguous，不自动认定

统一集成契约（每个 Server 均须声明）

- 协议 MCP over stdio / SSE
- 鉴权 Higress 签发 consumer token，Worker 无长期密钥
- 输入输出 Schema JSON Schema，运行时强校验
- 幂等控制 写操作必带 idempotency_key
- 审计记录 每次调用写审计日志，TraceId 关联

Mock ↔ 真实：为什么零差异

Mock Server 与真实适配器实现同一个 MCP Tool 定义文件，Schema 由同一份 schema.json 生成，契约测试对两者跑同一套用例。

因此 Demo 中验证过的调用链、失败分支与幂等行为，在真实接入后语义完全一致。

权限边界与 PII 收敛

两个 PII 数据源（征信、流水）只对 DueDiligence 一个 Worker 开放。因取证触点唯一，Higress 的出站脱敏规则只需覆盖单一路径，脱敏范围可收敛、可验证。

写权限仅对 Executor 开放，且必须携带审批 token 验签。

后续迁移到生产 MCP 的成本：仅需替换 Server 内部实现与鉴权配置，Agent、Skill、路由表与契约测试均无需改动。

RAG 四项能力全做（赛题要求至少两项）

RAG 在本方案中不是「检索增强」的装饰，而是**证据链的一部分**—— 每条召回结果自动登记 evidence_id，成为可举证的决策依据。

01 Agent 记忆存储

Skill: CaseMemory

存储会话历史与决策上下文，支持**时间窗查询 + 向量语义检索**。作用域分 case / session 两级。

无相似案例时**明确返回空集**，不用低相似度结果凑数。

02 知识库 RAG

Skill: PolicyRag

面向信贷政策、监管规则、行内制度与历史处置案例，pgvector 实现向量化与相似度检索，支持按**条款生效日期**过滤。

召回为空时返回 no_policy_matched，**绝不编造条款**。

03 共享状态管理

组件: Case State Store

保存上下文、任务状态、**幂等键**、审批结果与证据索引。并发一致性靠**乐观锁 + RocketMQ 顺序消息**，同一 case_id 路由至同一队列。

与 Matrix 消息流分离存储，以 case_id 关联。

04 轨迹可观测

组件: 证据账本 + OTel Trace

执行轨迹与证据链持久化，支持**全链路回放与审计**。审计官据此重建「谁在何时依据什么做了什么」。

账本 append-only，Trace 保留原始 Span。

「召回即证据化」—— 本方案对 RAG 的特殊约束

常规 RAG 把召回内容拼进 prompt 就结束了，结论与来源之间没有可验证的绑定关系，事后无法举证「这条结论依据的是哪一版政策」。

本方案要求：**每条召回结果在进入推理上下文前，先经 EvidenceLedger 登记为一条证据**，带条款出处、生效日期与内容哈希。RiskAnalyst 的结论 Schema 强制引用这些 evidence_id。

效果：报告正文的每一处政策依据都能点回原文；政策改版后可批量识别「哪些历史结论依据的是旧版条款」。

上下文在 Agent 间如何传递

载体	承载内容	特性
Matrix 消息	事件、结论摘要、结论引用	人可读 可介入
Case State	任务状态、幂等键、审批结果、证据索引	强一致 机器可查
MinIO 对象	证据原文快照、报告产物	大对象 不进消息体
OTel Trace	路由决策、Skill / MCP / LLM 调用	可回放 可审计

零人工不等于无限自动化

动作按 风险等级 × 证据等级 × 敞口金额 × 可逆性 四维定级。核心红线：不可逆动作永不自动执行。

L0 只读诊断

输出风险报告与建议，不触碰任何业务系统。

全自动

无需审批

典型：维持原状 + 加强监测

L1 低风险自动执行

执行完全可逆、不影响客户授信可用额度的动作。

全自动

可逆

幂等

典型：打标关注、发起补充资料通知

L2 灰度 + 审批

影响客户授信但可回滚。房间内 @ 风险经理，等审批回调查验签后执行。

需审批

带回滚点

留痕

典型：额度压降、追加担保

L3 只生成方案

不可逆或影响重大的动作。Agent 永不执行，仅产出方案与证据包供人工决策。

人工决策

Agent 无执行权

典型：提前收贷、诉讼保全

安全执行五项前置条件

- 动作白名单 白名单外动作一律拒绝
- 幂等键 重复投递返回首次结果
- 回滚点 执行前落 rollback_point
- 审批验签 L2 校验 approval_token 签名
- 双写审计 动作前后快照 + 审计流水号

Fail-safe，不是 fail-open

RiskGate 遇到任何入参缺失或规则未命中，默认降级为 L3 —— 即最保守档位，只出方案不执行。

而不是「规则没匹配上就放行」。这是安全系统与演示系统的根本区别。

RiskGate 为纯规则引擎、无外部依赖：安全判定不依赖网络可用性，也不依赖 LLM 的当次发挥。

回滚与审计闭环

回滚 执行中断按 rollback_point 自动冲正额度；回滚失败即冻结 Case 并升级人工，不做二次尝试。

审计 ComplianceAuditor 独立核验处置是否真实生效，逐条校验监管合规项，发现缺失只报告不修复 —— 审计者不得成为修复者。

在银行场景，「敢自动执行」的前提是「随时能收回」—— 可回滚性决定自动化边界，而不是模型能力

可观测、评测指标与运行证据

遵循 OpenTelemetry GenAI 语义规范，覆盖 Agent / Skill / MCP / RAG / LLM 全链路 Span，并额外定义一类本方案特有的 routing Span。

TRACE 结构（主链路实测）

```
case CASE-2026-0814-001 ..... 8m02s
├─ agent signal-hub ..... 28s
│   └─ skill SignalFusion ..... 11s
├─ routing INTAKE→EVIDENCE ..... 0.3s
│   rule_id=R-02 version=v1.4.0
├─ agent due-diligence ..... 92s
│   └─ mcp judicial-mcp.search ..... 4.1s
│       └─ mcp txn-mcp.query ..... 7.8s
│           └─ skill EvidenceLedger ×11 ..... 3.2s
├─ routing EVIDENCE→ADJUDICATION
├─ agent risk-analyst ..... 34s
├─ agent devils-advocate ..... 31s
├─ adjudication 分歧 → 采信定性方
├─ skill RiskGate → L2 ..... 0.1s
├─ approval 等待人工 ..... 61s
├─ agent disposition-executor ..... 12s
└─ agent compliance-auditor ..... 47s
```

证据位：PoC 实测 Trace 导出至 poc/out/trace.json，Jaeger 截图与 Element 房间协作截图见代码包 poc/out/。

评测指标与 DEMO 目标

指标	定义	目标
预警降噪率	无效预警压降比例	≥ 60%
风险定性准确率	vs 专家标注 golden set	≥ 85%
误杀率	正常客户被误处置比例	≤ 2%
端到端处置时长	信号进入 → 意见书生成	分钟级
证据完备率	结论挂载证据的比例	100%
无证据结论率	未挂载证据即下结论	0
审批覆盖率	L2/L3 动作经审批比例	100%
回滚成功率	处置回滚演练成功率	100%

评估方式与数据回流

基于案例回放数据集做离线评估：规则评估（证据完备性、闸门定级正确性）+ LLM-as-Judge（定性合理性）+ 人工标注（golden set）。

评估结果回流两处：Badcase 进 Skill 的 eval/ 回归集（成为发布门禁），确认的风险模式经 PostmortemDistill 进 RiskPattern 知识库。

实现边界、复赛计划与开放 / 开源

我们清楚地说明当前做到了什么、没做什么、以及什么时候做 —— 边界写清楚，比把每个组件都说成已完成更可信。

初赛 V1.0

可演示

- 6 Worker 的 SOUL.md 与 Worker CR 声明
- SOP 五阶段路由状态机 + 路由表
- 14 个 Skill 的 Schema 与函数化实现
- 4 个 Mock MCP Server (真实 Schema)
- 证据账本 + Case State (Postgres + pgvector)
- 两条链路端到端跑通 + OTel Trace 落盘

尚未做：真实行内系统接入、生产级并发、完整 golden set 规模化标注。

复赛 V2.0

可验证

- 接入真实 Nacos 做 Skill / 路由表灰度与回滚
- Higress 网关落地凭证透传与 PII 出站脱敏规则
- 扩展评估集至 100+ 标注案例，产出评测报告
- 回滚与越权拦截的故障注入演练
- Manager 变厚：扩展至贷后 + 反欺诈 + 法务三 Team
- Element 房间内完整人工审批交互演示

开放 / 开源计划

可复用

- Agent 拆分法则 方法论文档，与业务解耦
- CreditSkill Spec Skill 规范三件套
- EvidenceLedger 证据账本组件 (最通用)
- RiskGate 四维执行闸门内核
- 4 个 MCP 接口契约 含契约测试用例
- 风险案例回放数据集 含误报陷阱样例

协议：核心组件 Apache-2.0；数据集 CC BY 4.0。

依赖披露与合规边界

项	说明
商业 API	LLM 推理调用商业模型 API，用于定性、质疑与成文三个环节。成本按单案 Token 计量并在 Metrics 中披露
闭源模型	可替换为开源模型，Prompt 与 Skill Schema 不变；已在 eval 集上保留可对比的模型切换基线
第三方依赖	AgentTeams、Higress、Nacos、RocketMQ、PostgreSQL + pgvector、MiniIO、OpenTelemetry，均为开源组件
数据来源	合成数据 + 公开数据，无真实客户数据，无需数据授权，无个人信息合规风险
已有项目	本项目为全新构建，未基于团队既有项目二次开发

可复现方式

```
docker compose up -d
python poc/run_demo.py --case CASE-001 # 链路 A
python poc/run_demo.py --case CASE-002 # 链路 B
```

产出落于 poc/out/：Trace、结构化日志、处置意见书、审计报告。PoC 默认走开源替代组件，无需任何云账号即可完整复现。

README 提供环境要求、依赖安装、配置方法与逐步复现说明。